



Proyecto Final Computer Vision 2025

Clasificación de residuos

Maestría en Ciencia de Datos y
Aprendizaje Automático

Joana Auriello y Pablo Molina

Agenda

1. Conformación de base de datos de imágenes (fuentes)
2. Pre procesamiento: etiquetado y data augmentation
3. Entrenamiento ResNet50
4. Entrenamiento Efficientnet
5. Entrenamiento YOLO
6. Resultados de modelos y comparación
7. Ejemplos de clasificación de una nueva imagen

Conformación de base de datos de imágenes (fuentes)

Conformación de base de datos de imágenes (fuentes)

1. Cantidad de imágenes: ~60.000

2. Clases (categorías):

- 2.1. Bio organico
- 2.2. Envase plasticos
- 2.3. Papel y carton
- 2.4. Reciclables Varios cigarro
- 2.5. Reciclables Varios Electrónicos
- 2.6. Reciclables Varios Madera
- 2.7. Reciclables Varios Metal
- 2.8. Reciclables Varios Otros
- 2.9. Reciclables Varios Plastico
- 2.10. Reciclables Varios Textiles
- 2.11. Reciclables Varios Vidrio
- 2.12. Todo lo demas (no reciclable)



Datasets Utilizados

Cada uno de estos dataset contaban con categorías distintas que fueron unificadas para el proyecto:

<https://universe.roboflow.com/material-identification/garbage-classification-3/dataset/2>

<https://www.kaggle.com/datasets/mascot9183/garbage-pictures-for-classification?select=Garbage+classification>

<https://www.kaggle.com/datasets/mostafaabla/garbage-classification>

<https://www.kaggle.com/datasets/sumn2u/garbage-classification-v2/>

<https://www.kaggle.com/datasets/xiaohoua/garbage-huawei>

<https://www.kaggle.com/datasets/sarity/dataset-de-reciclaje>

Problema

- Clasificar residuos automáticamente a partir de imágenes reales (No de studio).
- Alta variabilidad visual: materiales, formas, iluminación y ruido.
- Clases desbalanceadas y algunas muy difíciles de distinguir.


Ejemplos de imágenes en el dataset



**Pre procesamiento: etiquetado y
data augmentation**

Pre procesamiento: etiquetado y data augmentation


1. Etiquetado de las imágenes por nombre de carpeta → Generación de image_labels.csv
2. No Augmentation vs Offline Augmentation vs Online Data Augmentation
3. Train (80%)/val(10%)/test(10%) split
4. Configuraciones generales: 224x224 px, Batch size 32
 - a. Transformaciones Train:
 - i. Rescale: rango [0,1] (solo ResNet)
 - ii. Horizontal Flip
 - iii. Rotation Range+- 15
 - iv. Zoom Range
 - v. Brightness Range: entre 0.8 y 1.2
 - b. Transformaciones Validation/test
 - i. Rescale: no se aplica augmentation para mantener evaluación consistente.



ResNet50

ResNet50

Descripción de la Arquitectura (ResNet-50)



Resnet-50 Model architecture


Estructura del *Backbone* de ResNet-50

- Red neuronal convolucional profunda con **5 etapas principales**.
- Utiliza **skip connections** (bloques residuales) para evitar el problema de vanishing gradients.
- Extrae características visuales de manera jerárquica:
 - **Capas tempranas** → bordes, texturas, colores
 - **Capas intermedias** → formas, partes de objetos
 - **Capas tardías** → características semánticas de alto nivel

Clasificador Original de ResNet-50

- *Avg Pool* → *Flatten* → *Fully Connected* (1000 clases de ImageNet)
- Este clasificador fue **removido en nuestro proyecto** y reemplazado por un **clasificador personalizado**:

ResNet50 → **Global Average Pooling** → **Dropout(0.3)** → **Dense(12, softmax)**



Training Pipeline - ResNet50

ResNet50

Resumen del proceso de entrenamiento

1. Entrenamiento en 2 fases

- Fase 1: se entrena solo el classifier head (backbone congelado)
- Fase 2: se habilita el entrenamiento del 30% superior del backbone

2. Función de pérdida: Sparse categorical cross-entropy

3. Optimizador: Adam

- LR Fase 1: 1e-3
- LR Fase 2: 1e-5

4. Callbacks:

- EarlyStopping (val_loss)
- ReduceLROnPlateau
- ModelCheckpoint (el mejor en ambas fases)

Model: "functional"

Layer (type)	Output Shape	Param #
input_layer_1 (InputLayer)	(None, 224, 224, 3)	0
resnet50 (Functional)	(None, 7, 7, 2048)	23,587,712
global_average_pooling2d (GlobalAveragePooling2D)	(None, 2048)	0
dropout (Dropout)	(None, 2048)	0
dense (Dense)	(None, 12)	24,588

Total params: 23,612,300 (90.07 MB)

Trainable params: 24,588 (96.05 KB)

Non-trainable params: 23,587,712 (89.98 MB)

4. Balanceo de clases: cálculo de class_weights según la distribución del dataset.

5. Steps por epoch:

- Fase 1: 800
- Fase 2: 400

Métricas - Resnet50

Eval ResNet50

Augmented

Not Augmented

Test Accuracy: 0.4447

Test Loss: 1.6543

Test Accuracy: 0.4731

Test Loss: 1.5809

Correctly classified test images: 2628

Incorrectly classified test images: 3282

Classification Report (TEST):

	precision	recall	f1-score	support
→ Bio organico	0.77	0.44	0.56	769
Envase Plasticos	0.33	0.45	→ 0.38	399
→ Papel y Carton	0.50	0.38	→ 0.43	929
Reciclables Varios Cigarro	0.04	0.71	0.08	17
Reciclables Varios Electronicos	0.37	0.47	0.41	333
Reciclables Varios Madera	0.15	0.63	0.25	84
→ Reciclables Varios Metal	0.21	0.33	0.26	309
→ Reciclables Varios Otros	0.10	0.49	0.16	91
Reciclables Varios Plastico	0.35	0.23	0.28	312
Reciclables Varios Textiles	0.75	0.61	0.67	1724
→ Reciclables Varios Vidrio	0.54	0.31	→ 0.40	706
→ Todo lo demás	0.21	0.16	0.18	237
accuracy			0.44	5910
macro avg	0.36	0.44	0.34	5910
weighted avg	0.55	0.44	0.48	5910

Correctly classified test images: 2796


Incorrectly classified test images: 3114

Classification Report (TEST):

	precision	recall	f1-score	support
→ Bio organico	0.65	0.66	→ 0.66	769
Envase Plasticos	0.31	0.47	0.37	399
→ Papel y Carton	0.64	0.38	→ 0.48	929
Reciclables Varios Cigarro	0.07	0.65	0.12	17
Reciclables Varios Electronicos	0.43	0.44	0.44	333
→ Reciclables Varios Madera	0.16	0.64	0.26	84
Reciclables Varios Metal	0.22	0.33	0.26	309
→ Reciclables Varios Otros	0.12	0.41	0.18	91
Reciclables Varios Plastico	0.31	0.37	0.34	312
Reciclables Varios Textiles	0.81	0.55	0.66	1724
→ Reciclables Varios Vidrio	0.52	0.36	→ 0.43	706
→ Todo lo demás	0.22	0.28	0.25	237
accuracy			0.47	5910
macro avg	0.37	0.46	0.37	5910
weighted avg	0.57	0.47	0.50	5910

Eval ResNet50


Augmented



Confusiones particularmente fuertes

1. **Textiles** → **Vidrio** (y viceversa)
A pesar de valores altos en la diagonal, se observan confusiones notables en ambas direcciones.
2. **Plástico** → **Otros** / **Metal** / **Papel y Cartón**
Se confunde por similitud de formas y colores.
3. **Metal** → **Vidrio** / **Otros**: Indica que el modelo no capta bien las características distintivas.


Not Augmented



Eval ResNet50

Not Augmented

ROC Curves (TEST) - resnet50_noaug_v2




Curvas ROC por clase, que muestran qué tan bien separa el modelo cada categoría.

→ Todas las clases están **por encima de 0.79**, lo cual es bueno: el modelo sí sabe separar las clases; sus errores ocurren principalmente en el umbral de decisión, no en la capacidad de representación del backbone.

Histograma de confianza, que permite ver si el modelo es coherente entre su nivel de certeza y si acierta o se equivoca.

- El modelo acierta cuando está muy seguro
- La mayoría de errores ocurren con baja confianza
- Pocas predicciones incorrectas con probabilidad alta

Correct vs Incorrect Prediction Confidence - resnet50_noaug_v2



Eval ResNet50

Augmented

Not Augmented

Correctly classified test images - resnet50_with_aug_v2

True: Reciclables Varios Vidrio
Pred: Reciclables Varios Vidrio (0.31)



True: Reciclables Varios Textiles
Pred: Reciclables Varios Textiles (0.66)




True: Reciclables Varios Textiles
Pred: Reciclables Varios Textiles (0.94)



Correctly classified test images - resnet50_noaug_v2

True: Bio organico
Pred: Bio organico (0.17)



True: Bio organico
Pred: Bio organico (0.56)



True: Reciclables Varios Vidrio
Pred: Reciclables Varios Vidrio (0.36)



Incorrectly classified test images - resnet50_with_aug_v2


True: Reciclables Varios Textiles
Pred: Reciclables Varios Electronicos (0.25)



True: Reciclables Varios Textiles
Pred: Reciclables Varios Metal (0.44)



True: Papel y Carton
Pred: Envase Plasticos (0.28)



Incorrectly classified test images - resnet50_noaug_v2

True: Reciclables Varios Electronicos
Pred: Papel y Carton (0.50)



True: Reciclables Varios Vidrio
Pred: Bio organico (0.25)



True: Reciclables Varios Electronicos
Pred: Reciclables Varios Textiles (0.54)



Beispiel

Model Demo - Resnet50

```
[resnet50_with_aug_v2] Loading best Phase 2 model for p  
1/1 ————— 4s 4s/step
```

```
[resnet50_with_aug_v2] Predictions for: /content/drive/  
Todo lo demás: 0.2325  
Reciclables Varios Madera: 0.1675  
Reciclables Varios Textiles: 0.1438
```

Top-1: Todo lo demás (0.23)



```
[resnet50_noaug_v2] Loading best Phase 2 model fo  
1/1 ————— 4s 4s/step
```

```
[resnet50_noaug_v2] Predictions for: /content/dri  
g
```

```
Reciclables Varios Plastico: 0.2135  
Reciclables Varios Madera: 0.1520  
Papel y Carton: 0.0972
```

Top-1: Reciclables Varios Plastico (0.21)






EfficientNet

Desarrollado por Google Brain para conseguir mejores resultados con menor costo computacional y latencia.


La revolución de este modelo se dio por combinar la idea Squeeze Excite + un método llamado Compounding Scaling

Arquitectura del modelo



La técnica Compound Scaling escala en conjunto la profundidad, ancho y resolución de la imagen a la hora de entrenar.


Con esto EfficientNet consigue igual o mejor resultados con menos parámetros.



Depth $d = \alpha^\emptyset$, Width $w = \beta^\emptyset$, Resolution $r = \gamma^\emptyset, (1)$

such that $\alpha.\beta^2.\gamma^2 \approx 2$

$\alpha \geq 1, \beta \geq 1, \gamma \geq 1$



EfficientNetBo

Resumen del proceso de entrenamiento

1. Entrenamiento en 2 fases

- Fase 1: se entrena solo el classifier head (backbone congelado)
- Fase 2: se habilita el entrenamiento sin las últimas 20 layers

2. Función de pérdida: Sparse categorical cross-entropy

3. Optimizador: Adam

- LR Fase 1: 1e-3
- LR Fase 2: 1e-5

4. Callbacks:

- EarlyStopping (val_loss)
- ReduceLROnPlateau
- ModelCheckpoint (el mejor en ambas fases)

4. Balanceo de clases: cálculo de class_weights según la distribución del dataset.

5. Steps por epoch:


- Fase 1: 800
- Fase 2: 400

Resultado de EfficientNet

Spoiler: son malos



Classification Report (TEST):



	precision	recall	f1-score	support
Bio organico	0.60	0.59	0.59	769
Envase Plasticos	0.15	0.14	0.14	399
Papel y Carton	0.44	0.13	0.20	929
Reciclables Varios Cigarro	0.04	0.06	0.05	333
Reciclables Varios Electronicos	0.02	0.12	0.04	84
Reciclables Varios Madera	0.05	0.10	0.06	309
Reciclables Varios Metal	0.01	0.12	0.02	91
Reciclables Varios Otros	0.02	0.03	0.02	312
Reciclables Varios Plastico	0.19	0.04	0.06	1724
Reciclables Varios Textiles	0.02	0.03	0.02	706
Reciclables Varios Vidrio	0.12	0.02	0.04	237
Todo lo demás	0.00	0.00	0.00	0
accuracy			0.13	5910
macro avg	0.13	0.10	0.10	5910
weighted avg	0.23	0.13	0.15	5910

Posibles causas:

- Descongelar más layers de las necesarias
- Falta de imagenes
- Abrir las subcategorias
- Errores en el augmentation (Usamos el mismo que el resnet)
- Errores en el pipeline (Practicamente el mismo que para resnet)

Layer (type)	Output Shape	Param #
input_layer_1 (InputLayer)	(None, 224, 224, 3)	0
efficientnetb0 (Functional)	(None, 7, 7, 1280)	4,049,571
global_average_pooling2d (GlobalAveragePooling2D)	(None, 1280)	0
dropout (Dropout)	(None, 1280)	0
dense (Dense)	(None, 13)	16,653

Total params: 4,066,224 (15.51 MB)
Trainable params: 16,653 (65.05 KB)
Non-trainable params: 4,049,571 (15.45 MB)

Layer (type)	Output Shape	Param #
input_layer_1 (InputLayer)	(None, 224, 224, 3)	0
efficientnetb0 (Functional)	(None, 7, 7, 1280)	4,049,571
global_average_pooling2d (GlobalAveragePooling2D)	(None, 1280)	0
dropout (Dropout)	(None, 1280)	0
dense (Dense)	(None, 13)	16,653

Total params: 4,066,224 (15.51 MB)
Trainable params: 3,071,273 (11.72 MB)
Non-trainable params: 994,951 (3.80 MB)


Layer (type)	Output Shape	Param #
input_layer_1 (InputLayer)	(None, 224, 224, 3)	0
efficientnetb0 (Functional)	(None, 7, 7, 1280)	4,049,571
global_average_pooling2d (GlobalAveragePooling2D)	(None, 1280)	0
dropout (Dropout)	(None, 1280)	0
dense (Dense)	(None, 13)	16,653

Total params: 4,066,224 (15.51 MB)
Trainable params: 1,359,421 (5.19 MB)
Non-trainable params: 2,706,803 (10.33 MB)

YOLOv8-cl

YOLOv8-cls

Descripción de la Arquitectura (yolov8n-cls)



YOLOv8 para Clasificación Arquitectura liviana optimizada para image classification.

Modelos pre-entrenados (yolov8n-cls.pt, yolov8s-cls.pt, etc.) basados en CNN modernas + capas eficientes.

Se utiliza un backbone convolucional seguido de:


- Global Average Pooling
- Capa Fully Connected con activación softmax

Diseñado para:

- Entrenamiento rápido
- Alta eficiencia computacional
- Buen rendimiento con datasets medianos/pequeños

Tareas soportadas por YOLOv8

- Detección
- Segmentación
- Pose
- Clasificación



Training Pipeline - YOLOv8n-cls

YOLOv8-cls

Adaptaciones realizadas a YOLOv8 para clasificación de residuos

Componente	Descripción
Estructura del dataset	Se crea automáticamente /train, /val, /test con carpetas por clase.
Uso de symlinks	En lugar de copiar 10.000+ imágenes, se generan enlaces simbólicos → entrenamiento más eficiente.
Split estratificado	80% train / 10% val / 10% test manteniendo distribución por clase.
Modelo utilizado	yolov8n-cls.pt (nano): liviano y rápido
Hiperparámetros definidos	epochs=20, imgsz=224, batch=64, workers=2, val=True.
Data augmentation	No aplicamos augmentations manuales → entrenamiento limpio para comparar con ResNet50 sin augmentación.

YOLOv8-cls

Hiperparámetros del Entrenamiento y Justificación

Hiperparámetro	Valor	Justificación
Épocas	20	Suficiente para convergencia rápida de YOLO en clasificación.
Batch size	64	Para optimizar CPU de Colab, maximiza rendimiento.
Tamaño de imagen	224×224	Consistente con ResNet50 y EfficientNet → comparación justa.
Optimizador	Adam (default)	Rápido y estable para entrenamiento con dataset heterogéneo.
Loss	Cross-Entropy	Adecuado para clasificación multiclase.
Modelo base	yolov8n-cls (pretrained en ImageNet)	Modelo liviano para prototipar con bajo costo computacional.

Métricas - YOLOvs8-cls

Eval YOLOv8-cl

YOLOv8-cls obtiene un **accuracy 10-12 puntos más bajo** que ResNet50.

Confusion Matrix: confusiones extremas.

- Textiles → Vidrio (y vice)
- Plastico → Metal


Predicciones concentradas en:

- Bio organico,
- Envase Plasticos,
- Papel y Carton

→ **Test Accuracy: 0.3506** | **Correctly classified test images: 2072** | **Incorrectly classified test images: 3838**

```
=== YOLOv8 CLASSIFICATION REPORT (TEST) ===
```

	precision	recall	f1-score	support
→ Bio organico	0.50	1.00	0.66	769
→ Envase Plasticos	0.20	0.97	0.33	399
→ Papel y Carton	0.38	0.99	0.55	929
Reciclables Varios Cigarro	0.00	0.00	0.00	17
Reciclables Varios Electronicos	0.00	0.00	0.00	333
Reciclables Varios Madera	0.00	0.00	0.00	84
Reciclables Varios Metal	0.00	0.00	0.00	309
Reciclables Varios Otros	0.00	0.00	0.00	91
Reciclables Varios Plastico	0.00	0.00	0.00	312
Reciclables Varios Textiles	0.00	0.00	0.00	1724
Reciclables Varios Vidrio	0.00	0.00	0.00	706
Todo lo demás	0.00	0.00	0.00	237
accuracy			0.35	5910
macro avg	0.09	0.25	0.13	5910
weighted avg	0.14	0.35	0.19	5910




Eval YOLOv8-cls

- **Mayoría de predicciones de probabilidad alta**



→ El modelo está extremadamente confiado hasta cuando se equivoca.

- **El accuracy de validación es muy alto pero no representa el desempeño real, ya que el test accuracy fue solo 0.35.**


→ Hay overfitting: el modelo "aprendió" demasiado bien el conjunto de validación pero no generaliza.



Correct predictions: 2072
Incorrect predictions: 3838



Eval YOLOv8-cls



Algunas clases están extremadamente bien separadas, lo que demuestra que el backbone de YOLOv8 sí puede extraer buenas features para ciertos materiales.

Muchas clases tienen AUC entre 0.52-0.66 → el modelo apenas logra separarlas del resto. --> Mismo patrón que vimos en matriz de confusión y clasificación: el modelo colapsa estas clases.

Conclusiones grales:

- Sobreconfianza alta → problemas de seguridad
- Excelente desempeño en pocas clases, pero colapso total en varias otras
- Validación engañosa (overfitting fuerte)
- Mala capacidad para separar clases complejas
- Peor generalización que ResNet50 por amplio margen

Eval YOLOv8-cls

Correctly classified test images - yolo_cls_noaug_v1

True: Envase Plasticos
Pred: Envase Plasticos (1.00)



True: Bio organico
Pred: Bio organico (1.00)



True: Envase Plasticos
Pred: Envase Plasticos (1.00)



True: Reciclables Varios Textiles
Pred: Envase Plasticos (0.85)



True: Reciclables Varios Textiles
Pred: Bio organico (0.93)



True: Reciclables Varios Textiles
Pred: Papel y Carton (0.93)



True: Bio organico
Pred: Bio organico (1.00)



True: Papel y Carton
Pred: Papel y Carton (1.00)



True: Bio organico
Pred: Bio organico (1.00)



True: Reciclables Varios Plastico
Pred: Papel y Carton (0.97)



True: Reciclables Varios Textiles
Pred: Papel y Carton (0.99)



True: Reciclables Varios Electronicos
Pred: Papel y Carton (1.00)



Resultados de modelos y comparación

Eval Comparativa



Métrica Test	Resnet50 - Aug	Resnet50 - No Aug	EfficientNet - Aug	YOLO - No Aug
Accuracy	0.4447	0.4731	0.1333	0.3506
Correctly classified images	2628	2796	788	2072
Incorrectly classified images	3282	3114	5122	3838

Conclusiones

- El dataset necesita mejoras: más ejemplos, clases más balanceadas y augmentation mejor diseñada.
- Algunas categorías deben redefinirse para reducir su heterogeneidad.
- ResNet50 sin augmentation fue el modelo con mejor desempeño en test.
- Su mejor rendimiento se explica por una generalización más estable y la efectividad del fine-tuning.
- YOLOv8 mostró fuerte sobreajuste: buen entrenamiento pero baja generalización.
- En conjunto, los resultados confirman que la clasificación de residuos es un problema complejo y sensible a la variabilidad del dataset.

Recursos

- Todos los recursos utilizados para el proyecto pueden ser encontrados en el siguiente [repositorio](#).

iMuchas gracias!